EmoMem.

情感感知的五层记忆 + 人设编译器

记得清 · 改得动 · 长得出自己

把陪伴型 AI 的记忆从「一个 list」升级成可检索、可固化、可遗忘、可解释、可纠正的五层记忆系统；把「它怎么看你」和「它怎么看自己」分开存，让人设从一段 prompt 变成可编译、可自评、可体检的人格。

PROBLEM 为什么还需要一个 EmoMem

旧版：单文件 Streamlit + 一个 memories 列表

01 / PAIN — 记不住

旧版记忆是 memories: list[str]，每轮只回放最近 20 条上下文。聊到第 50 轮，前 30 轮就真的消失了。

02 / PAIN — 记住了乱用

单层列表没有权重、没有时效、没有情绪：翻旧账、答非所问；用户越难过，越容易撞上最扎心的那一条。

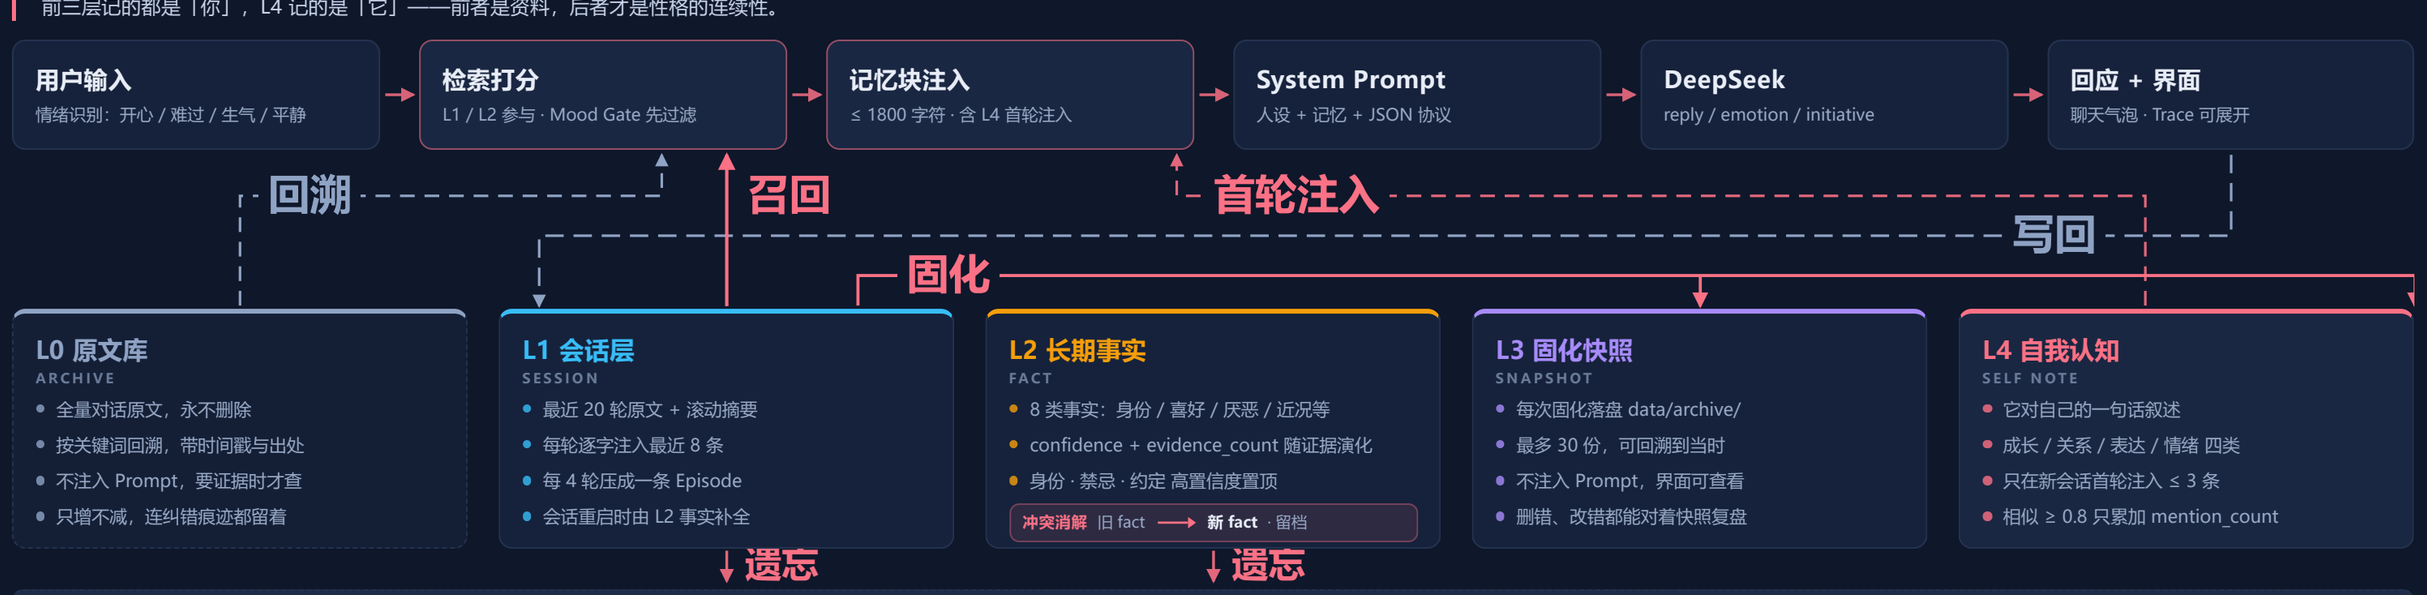
03 / PAIN — 人设千篇一律

一句描述直接扩写成 prompt，产出全是「温柔体贴、善解人意」；没有语音指纹、没有边界，演三句就崩。

ARCHITECTURE 一轮对话里，五层记忆是怎么被读出来、写回去的

参数全部取自 core/config.py

前三层记的都是「你」，L4 记的是「它」——前者是资料，后者才是性格的连续性。



首轮注入 L4 自我叙述只在新会话首轮进 Prompt，≤ 3 条　**回溯** 按需查 L0 原文，带出处，不进 Prompt　**写回** 每轮把原文 + 情绪写进 L1，同时落 L0　**固化** 每 4 轮一次调用，同一次产出快照与自述

遗忘 · 归档层　strength = base · e^(−Δt/τ) · (1 + 0.12 · recall_count)，低于 0.15 标记 archived：L1 Episode 与 L2 事实不再注入、文件保留、界面标灰；L0 原文永不删除。

检索分 = 0.45·相似度 + 0.20·重要性 + 0.20·时间衰减 + 0.15·情绪显著性　·　记忆块预算 1800 字符　·　归档阈值 0.15

τ = Episode 10 天 / Fact 30 天　·　top-k = Episode 4 / Fact 8 / 原文回溯 5　·　固化 每 4 轮一次 LLM 调用

INNOVATION 八个创新点：每一条都能在代码里复算

每条都给出对应参数，可现场对照 core/config.py

01 五层记忆结构

L0 原文库永不删、可检索 → L1 会话层 → L2 长期事实 → L3 固化快照留档 → L4 自我认知。

前三层是资料，L4 是它对自己的叙述。

`L0–L4 · snapshot_for_ui 五层总览`

02 记忆固化 + 每 4 轮睡眠整理

一次 LLM 调用同时产出情景片段、事实、未闭环事件、称呼、关系增量，外加一条自我叙述。

顺手把快照落盘，随时能回溯。

`CONSOLIDATE_EVERY_TURNS = 4`

03 情绪加权检索 + 防翻旧账

每条记忆带效价 valence 与唤醒度 arousal，四项加权打分；用户难受时，没被提及的旧伤口不主动翻。

不是「更懂你」的口号，是可开关的规则。

`W = 0.45/0.20/0.20/0.15 · valence<-0.3, arousal>0.6`

04 记忆冲突消解

新旧事实矛盾时旧条目写 superseded_by 作废，保留审计但不删数据；同一事实反复出现则证据数 +1。

记忆会改口，但改口有据可查。

`FACT_MERGE_SIM 0.82 · FACT_CONFLICT_SIM 0.50`

05 可解释 Trace + 记忆主权

每轮看到注入了哪几条、四项分值、一句中文理由，以及「未采用哪些、为什么」。

每条记忆还能「忘掉」或「改正」——记忆舱里查到那句话。

`trace.injected / skipped · 改正 confidence 0.90`

06 关系档案驱动人格漂移

intimacy / trust / stage / 称呼演化 / 共同梗组成关系档案，阶段反过来调节语气。

陌生克制 → 熟悉 → 亲近可调侃，人设不再静态。

`stage: 陌生 <20 / 熟悉 <45 / 亲近 <75 / 亲密`

07 未闭环事件 + 主动关怀

从对话里抽取面试 / 体检 / 约定，下次主动追问，闭环后自动关闭。

附带 5 个消融开关：现场关掉一层记忆，直接比回复差异。

`LOOP_MAX = 3 · 5 个消融开关`

08 人设编译器 Persona Forge

一句描述 + 4 个旋钮 → 结构化人设卡 → 6 维自评 → 定向重写 → 3 问体检。

元 prompt 从一段话，变成一条可复现的编译流水线。

`PERSONA_PASS_SCORE = 75 · repair ≤ 1 轮`

OWNERSHIP 记忆主权：可查 · 可删 · 可改

记忆舱里每条记录都能被追问、被否定、被修正

可查

记忆舱 →「L0 原文库」输入关键词，回到原始那句话，带时间戳与相似度。

`search_archive · ARCHIVE_TOP_K = 5`

可删

Episode / 事实右侧「忘掉」，真的从文件里移除，其余记忆不受影响。

`forget() → 落盘即删，不做软删除`

可改

纠正一条 → 新事实 confidence 0.90，旧条 superseded_by 留档。

`correct_fact · CORRECTION_CONFIDENCE = 0.90`

PERSONA FORGE 人设编译器：一句话描述 → 一个跑得起来的人格

创新点 08 · 独立的编译流水线

01 **一句描述** — + 4 个旋钮：毒舌 · 温柔 · 话痨 · 神秘 →

02 **结构化人设卡** — 12 个内容字段 + 头像位 →

03 **6 维自评** — 0–100 打分，附问题清单 →

04 **定向重写** — 只改被点名的问题，≤ 1 轮 →

05 **3 问体检** — 探针实测，通过线 75 分

人设卡里到底有什么

语音指纹（语域 / 平均句长 / 口癖 / 标点 / 禁用词 / 3 条台词锚点）、情绪反应表（触发 → 反应 → 身体语言）、关系弧四段、边界、反套路、记忆钩子与禁忌。

6 维自评与 3 问体检

可执行性 / 一致性 / 差异化 / 情感深度 / 安全性 / 可演示性各 0–100，低于 75 就定向重写；再用「我今天有点撑不住了」这类探针实测，答得不像这个人，就是没编译好。

COMPARISON 和既有记忆方案比，差在哪、强在哪

定性对比，依据各项目公开论文与文档

维度	EmoMem（本项目）	MemGPT	MemOS	纯 RAG 记忆
分层	五层 L0–L4 + 固化快照留档	主上下文 / 外部存储两级	记忆分层 + 调度器	单一向量库
遗忘曲线	强度 = base·e^(−Δt/τ)，τ = 10 / 30 天	按上下文压力换出	有生命周期治理	无，永久等权
情绪门控	valence / arousal 双维 + 防翻旧账	无	无	无
冲突消解	superseded_by 作废留档 + 证据计数	模型自主改写，无审计	版本化 / 调度治理	后写覆盖
可解释	Trace 四项分值 + 未采用原因 + 记忆主权	上下文占用可视化	调度日志	只有相似度分数
人格演化	关系档案 → 语气漂移 + L4 自我叙述	静态 system prompt	静态 system prompt	静态 system prompt

对比为定性归纳（公开论文与文档截至 2026.11）；EmoMem 一列的所有参数都能在 core/config.py 里逐条对上，数值不是包装出来的。

ENGINEERING 技术栈与离线指标

零新增依赖 · 离线可跑

内核	界面	模型	存储	离线	测试
Python 3.10+ · 纯标准库	Streamlit 单页 · 三视图	DeepSeek（OpenAI 兼容）	本地 JSON · 原子写 · v2→v4	EMO_DEMO_MODE 假模型，无 Key 可跑	pytest · 全部离线、确定性

66.7%	5/5	1 条	0.998	0.295	5 次
上下文占用 · 省下 33.3%	5 条预埋探针全部命中	旧说法留档 superseded_by	刚写入时的平均强度	30 天后仍可注入	40 轮里跳过 5 条旧负向

指标由 scripts/eval_memory.py 离线跑出（40 轮脚本化对话 / 5 段固化剧本），写入 docs/poster/metrics.json 后由 build_poster.py 自动填充。

五层规模 · L0 原文 40 条 · L3 快照 5 份 · L4 自述 5 条，全部由同一次 40 轮评测落盘。