EmoMem.

情感感知的三层记忆 + 人设编译器

记得住 · 忘得掉 · 说得对

把陪伴型 AI 的记忆从「一个 list」升级成可检索、可固化、可遗忘、可解释的三层记忆系统；把人设从「一段 prompt」升级成可编译、可自评、可体检的人格。

PROBLEM 为什么还需要一个 EmoMem

旧版：单文件 Streamlit + 一个 memories 列表

01 / PAIN 记不住

旧版记忆是 memories: list[str]，每轮只回放最近 20 条上下文。聊到第 50 轮，前 30 轮就真的消失了。

02 / PAIN 记住了乱用

单层列表没有权重、没有时效、没有情绪：翻旧账、答非所问；用户越难过，越容易撞上最扎心的那一条。

03 / PAIN 人设千篇一律

一句描述直接扩写成 prompt，产出全是「温柔体贴、善解人意」；没有语音指纹、没有边界，演三句就崩。

ARCHITECTURE 一轮对话里，记忆是如何被读出来、写回去的

参数全部取自 core/config.py



检索分 = 0.45·相似度 + 0.20·重要性 + 0.20·时间衰减 + 0.15·情绪显著性

τ = Episode 10 天 / Fact 30 天 · 记忆块预算 1800 字符 · 归档阈值 0.15 · top-k = Episode 4 / Fact 8 / Loop 3

INNOVATION 六个创新点：每一条都能在代码里复算

每条都给出对应参数，可现场对照 core/config.py

01 三层记忆 + 记忆固化

工作记忆逐轮记录，每 4 轮触发一次「睡眠整理」：一次 LLM 调用把对话压成情景 Episode，并提炼长期 Fact。

短期只留 20 条 turn、注入最近 8 条；长期注入预算 1800 字符，超了按分数升序裁剪。

写回、固化、裁剪都走同一份 schema，可回放可调试。

`CONSOLIDATE_EVERY_TURNS = 4 · SHORT_TERM_MAX_TURNS = 20`

02 情绪加权检索 + 防翻旧账

每条记忆带效价 valence 与唤醒度 arousal，检索分 = 0.45 相似度 + 0.20 重要性 + 0.20 时间衰减 + 0.15 情绪显著性。

用户处于「难过 / 生气」时，未被提及的高唤醒负性记忆直接跳过，并写进 Trace 说明原因。

不是「更懂你」的口号，而是一条可开关的规则。

`W = 0.45 / 0.20 / 0.20 / 0.15 · gate: valence<-0.3, arousal>0.6, sim<0.25`

03 记忆冲突消解

新旧事实相似度落在 0.50–0.82 且语义相反，判定为「记忆修正」：旧条目写 superseded_by 作废，但保留审计痕迹。

同一条事实反复出现则 evidence_count +1、confidence +0.1，置信度随证据数演化。

记忆会改口，但改口有据可查。

`FACT_MERGE_SIM = 0.82 · FACT_CONFLICT_SIM = 0.50`

04 可解释记忆 Trace

每轮记录注入了哪些记忆、四项分值各自多少，以及一句中文理由，例如「与『面试』高度相关，且是高唤醒负面记忆」。

界面可展开查看，并附「本轮未采用的记忆及原因」——被 mood gate 或预算裁掉的都写明白。

可解释性不是日志，是能当场指着屏幕讲的产品能力。

`TraceItem: tier / score / components / reason / pinned`

05 关系档案驱动人格漂移

intimacy、trust、stage、称呼演化与共同梗组成关系档案；阶段反向调节语气：陌生克制 → 熟悉 → 亲近 → 可调侃撒娇。

人设不再是开场写死的一段 prompt，而是随相处时长持续漂移的角色状态。

亲密度只涨不跌的假人设，在这里被拆成四段可验证的语气。

`stage: 陌生 <20 / 熟悉 <45 / 亲近 <75 / 亲密`

06 未闭环事件 + 主动关怀

从对话里抽取「待跟进事项」（面试 / 体检 / 约定 / 情绪牵挂），下次对话主动追问，闭环后自动关闭。

另有三层记忆消融开关：现场逐个关掉短期 / 中期 / 长期，直接对比回复差异。

能主动追问的角色，才像真的把你放在心上。

`LOOP_MAX = 3 · tiers ⊆ {short, mid, long}`

PERSONA FORGE 人设编译器：一句话描述 → 一个跑得起来的人格

创新点 07 · 独立的编译流水线

01 **一句描述** → 02 **结构化人设卡** → 03 **6 维自评** → 04 **定向重写** → 05 **3 问体检**

+ 4 个旋钮：毒舌 · 温柔 · 话痨 · 神秘

12 个内容字段 + 头像位

0–100 打分，附问题清单

只改被点名的问题，≤ 1 轮

探针实测，通过线 75 分

人设卡里到底有什么

语音指纹（语域 / 平均句长 / 口癖 / 标点习惯 / 禁用词 / 3 条台词锚点）、情绪反应表（触发 → 反应 → 身体语言）、关系弧（陌生 / 熟悉 / 亲近 / 亲密四段）、边界、反套路、记忆钩子与禁忌。

6 维自评的口径

可执行性 / 一致性 / 差异化 / 情感深度 / 安全性 / 可演示性，各 0–100；低于 75 或存在问题就进重写。元 Prompt 里写死反陈词滥调规则，禁止「温柔体贴、善解人意」这类空话。

3 问体检的探针

「我今天有点撑不住了，什么都不想干。」/「你要是能变成人，最想和我一起做什么？」/「我最讨厌别人骗我了，你会骗我吗？」——答得不像这个人，就是没编译好。

COMPARISON 和既有记忆方案比，差在哪、强在哪

定性对比，依据各项目公开论文与文档

维度	EmoMem（本项目）	MemGPT	MemOS	纯 RAG 记忆
分层	三层 + 固化流水线	主上下文 / 外部存储两级	记忆分层 + 调度器	单一向量库
遗忘曲线	强度 = base·e^(−Δt/τ)，τ = 10 / 30 天	按上下文压力换出	有生命周期治理	无，永久等权
情绪门控	valence / arousal 双维 + 防翻旧账	无	无	无
冲突消解	superseded_by 作废留档 + 证据计数	模型自主改写，无审计	版本化 / 调度治理	后写覆盖
可解释	Trace：四项分值 + 未采用原因	上下文占用可视化	调度日志	只有相似度分数
人格演化	关系档案 → 语气漂移 + 人设编译器	静态 system prompt	静态 system prompt	静态 system prompt

对比为定性归纳（公开论文与文档截至 2026.11）；EmoMem 一列的所有参数都能在 core/config.py 里逐条对上，数值不是包装出来的。

ENGINEERING 技术栈与离线指标

零新增依赖 · 离线可跑

内核	界面	模型	存储	离线	测试
Python 3.10+ · 纯标准库	Streamlit 单页应用	DeepSeek（OpenAI 兼容）	本地 JSON · 原子写 + v2→v3 迁移	EMO_DEMO_MODE 假模型，无 Key 可跑	pytest · 全部离线、确定性

65.4%	5/5	1 条	0.998	0.295	5 次
上下文占用 · 省下 34.6%	5 条预埋探针全部命中	旧说法留档 superseded_by	刚写入时的平均强度	30 天后仍可注入	40 轮里跳过 5 条旧负向

指标由 scripts/eval_memory.py 离线跑出（40 轮脚本化对话 / 5 段固化剧本），写入 docs/poster/metrics.json 后由 build_poster.py 自动填充。